

OBTENCIÓN DE DATOS PARA EL TFM

AI Financial Life Coach

Plataforma de Gestión Financiera Personal con IA

Asignatura	Obtención de Datos para el TFM (Asignatura 5)
Master	Big Data y Business Intelligence
Institucion	Next Educacion
Mercado objetivo	Espana — Segmento 25-40 anos
Fuentes	Eurostat API + Banco de Espana (Web Scraping)
Equipo	C. Cuaya - C. Solis - J. Caceres - M. Merola - M. Lozano

1. Introduccion

El presente trabajo corresponde a la Asignatura 5 del Master en Big Data y Business Intelligence de Next Educacion y tiene como objetivo obtener, preparar y documentar los datos que sirvan de base para el Trabajo Fin de Master (TFM) del grupo: AI Financial Life Coach, una plataforma digital de gestion financiera personal basada en analitica de datos y modelos de aprendizaje automatico, dirigida al mercado espanol.

El contexto macroeconomico espanol es determinante para justificar la oportunidad de negocio del producto. En un entorno de descenso del Euribor, recuperacion del ahorro familiar post-pandemia y morosidad bancaria en minimos historicos, existe una ventana favorable para el lanzamiento de una herramienta que ayude a los ciudadanos a gestionar mejor sus finanzas personales. Los datos obtenidos permiten cuantificar esta oportunidad y validar las hipotesis del modelo de negocio.

El mercado objetivo son jovenes profesionales de 25 a 40 anos residentes en Espana, con ingresos regulares o variables, alta adopcion digital y necesidad de ordenar sus finanzas sin conocimientos especializados. Los indicadores seleccionados — ahorro, desempleo juvenil, Euribor y morosidad — caracterizan directamente este segmento y su comportamiento financiero.

2. Descripcion de las Fuentes Utilizadas

Los datos han sido recopilados mediante las dos vias obligatorias establecidas por el enunciado del trabajo: consumo de API REST y web scraping. Ambas fuentes son institucionales y de acceso publico, lo que garantiza la veracidad, reproducibilidad y adecuacion etica del proceso.

2.1 API REST — Eurostat Statistics API

Eurostat es la oficina estadistica de la Union Europea y publica datos macroeconomicos oficiales de todos los Estados miembros a traves de una API REST publica, gratuita y sin autentificacion. La estructura de la URL permite filtrar por pais (geo=ES), indicador y periodo directamente en el request HTTP, devolviendo los datos en formato JSON-stat.

Dataset Eurostat	Indicador	Relevancia para el TFM
nasq_10_ki	Tasa de ahorro bruto hogares (%)	Cuantifica la capacidad de ahorro del mercado objetivo
une_rt_a	Desempleo 25-34 anos (%)	Caracteriza la precariedad laboral del segmento target
prc_hicp_manr	IPC variacion anual (%)	Contexto de poder adquisitivo y presion inflacionaria

2.2 Web Scraping — Banco de Espana y Wikipedia

El Banco de Espana publica mensualmente los datos de morosidad bancaria en su Boletin Estadistico (Capitulo 4). Estos datos, junto con la serie historica del Euribor obtenida mediante scraping de Wikipedia, complementan la perspectiva de riesgo crediticio del mercado financiero espanol. La extraccion se realiza con las librerias requests y BeautifulSoup, incluyendo un User-Agent adecuado para respetar las politicas de acceso de los sitios.

Fuente	Metodo	Indicador	Periodo
Banco de Espana	Scraping + datos verificados	Tasa de morosidad (%)	2008-2024
Wikipedia / BdE	Scraping + datos verificados	Euribor 12m media anual (%)	2008-2024

3. Proceso de Extraccion de Datos

3.1 Extraccion via API (Eurostat)

El proceso de extraccion via API sigue cuatro pasos. Primero, se construye la URL del endpoint combinando el codigo del dataset con los parametros de filtrado (geo=ES, format=JSON). Segundo, se realiza la peticion HTTP con requests.get() y se verifica el status code. Tercero, se parsea la respuesta

JSON-stat extrayendo las dimensiones temporales y los valores numericos. Cuarto, se construye un DataFrame de pandas y se guarda en CSV en el directorio data/raw/.

El codigo incluye un mecanismo de fallback: si la API devuelve un error por restricciones de red en el entorno de ejecucion, el script utiliza los datos historicos verificados directamente de los informes publicados por Eurostat, garantizando la reproducibilidad del pipeline en cualquier entorno.

3.2 Extraccion via Web Scraping (BdE)

El scraping del Banco de Espana sigue el patron aprendido durante el curso: `requests.get(url, headers={"User-Agent": "Mozilla/5.0 ..."})` para simular un navegador, seguido de `BeautifulSoup(response.text, "html.parser")` para parsear el HTML. Las tablas witable se extraen con `pd.read_html(StringIO(str(tabla)))`. Los datos de morosidad mensual se construyen a partir del Boletin Estadistico publicado mensualmente por el Banco de Espana.

4. Limpieza y Preparacion del Dataset

El proceso de limpieza se desarrolla en cuatro etapas documentadas en el notebook 03_limpieza/limpieza_preparacion.py.

- Eliminacion de duplicados: se verifica con `df.duplicated().sum()` que no existen registros duplicados en ninguno de los cinco datasets fuente. Resultado: 0 duplicados en todos los datasets.
- Tratamiento de valores faltantes: se detectan valores nulos con `df.isnull().sum()`. En caso de existir, se imputan por interpolacion lineal en variables temporales. Resultado: 0 valores faltantes en datos fuente.
- Estandarizacion de formatos: se extrae el ano y trimestre de los campos de periodo (formato "2024-Q1"), se convierten las variables numericas con `pd.to_numeric(errors="coerce")` y se renombran las columnas en snake_case.
- Construccion del dataset consolidado: los cinco datasets fuente se agregan a frecuencia anual y se unen mediante `merge(on="anio", how="outer")`, obteniendo un dataset final de 17 observaciones (2008-2024) x 8 variables.

Variable	Tipo	Unidad	Fuente
anio	Cuantitativa discreta	Ano	Calculada
tasa_ahorro_pct	Cuantitativa continua	%	Eurostat nasq_10_ki
tasa_desempleo	Cuantitativa continua	%	Eurostat une_rt_a
ipc_variacion_anual_pct	Cuantitativa continua	%	Eurostat prc_hicp_manr
euribor_pct	Cuantitativa continua	%	BdE / Wikipedia
tasa_morosidad_pct	Cuantitativa continua	%	Banco de Espana

5. Analisis Exploratorio de Datos (EDA)

El analisis exploratorio se centra en identificar los patrones y tendencias del contexto financiero espanol mas relevantes para el modelo de negocio de AI Financial Life Coach. Se presentan cinco visualizaciones principales.

5.1 Euríbor vs. Morosidad bancaria (2008-2024)

El grafico de doble eje revela una correlacion clara entre el nivel del Euríbor y la tasa de morosidad bancaria. En el periodo 2012-2013, cuando la morosidad alcanzo su maximo historico del 13,62%, el Euríbor ya habia descendido significativamente, reflejando la crisis financiera con retardo. El dato mas relevante para el TFM es el cierre de 2024 con morosidad en el 3,32% y Euríbor en descenso, configurando el entorno mas favorable para el lanzamiento del producto desde 2008.




Figura 1. Euríbor 12m y tasa de morosidad bancaria en España (2008-2024). Fuente: Banco de España + Eurostat.

5.2 Tasa de ahorro bruto de los hogares (2015-2024)

La tasa de ahorro presenta una tendencia estructural creciente interrumpida por el shock extraordinario de la pandemia en 2020, cuando llegó al 17,6%. Lo más significativo para el Financial Life Coach es que el ahorro se ha estabilizado en el 12,7% en 2024, muy por encima de la media pre-pandemia (~7,5%). Esto implica que existe una base creciente de hogares españoles con capacidad real de ahorro que no saben como optimizarlo — exactamente el problema que resuelve la plataforma.




Figura 2. Tasa de ahorro bruto de los hogares españoles (trimestral, 2015-2024). Fuente: Eurostat nasq_10_ki.

5.3 Desempleo juvenil (25-34 años) vs. Ahorro anual

El scatter plot muestra una relación negativa entre el desempleo del segmento 25-34 años y la tasa de ahorro. El dato de 2024 — desempleo en mínimos del 16,9% y ahorro en el 12,7% — sitúa al segmento objetivo en su mejor posición financiera desde 2008, aunque el desempleo juvenil sigue siendo el doble de la media EU, generando ingresos variables e irregulares en una fracción significativa del mercado target.




Figura 3. Relacion entre tasa de desempleo 25-34 anos y tasa de ahorro hogares. Fuente: Eurostat.

5.4 Evolucion mensual de la morosidad (2015-2024)

La serie mensual de morosidad bancaria muestra una tendencia bajista consistente desde el maximo del 13,62% en 2013 hasta el 3,32% en diciembre de 2024. Para AI Financial Life Coach, este contexto implica que los usuarios potenciales operan en un entorno financiero mas saneado, con menor riesgo de impago y mayor disposicion a contratar servicios digitales de gestion financiera.




Figura 4. Evolucion mensual de la tasa de morosidad bancaria en Espana (2015-2024). Fuente: Banco de Espana.

5.5 Matriz de correlacion entre variables financieras

La matriz de correlacion confirma correlacion positiva entre Euribor y morosidad (tipos altos se asocian a mayor impago) y correlacion negativa entre tasa de desempleo y tasa de ahorro. Estas relaciones son la base del modelo predictivo que alimentara las recomendaciones de AI Financial Life Coach.




Figura 5. Matriz de correlacion de Pearson entre las variables financieras del dataset. Fuente: elaboracion propia.

6. Exploracion con Streamlit

Como herramienta de exploracion interactiva, se ha desarrollado una aplicacion Streamlit (05_streamlit/app.py) que permite al equipo explorar el dataset de forma dinamica. La app incluye metricas principales en tiempo real (tasa de ahorro, morosidad, Euribor y desempleo del ultimo ano disponible con comparativa interanual), filtros interactivos en sidebar (seleccion de periodo y variables), visualizaciones dinamicas que se actualizan en funcion de los filtros, y descarga del dataset filtrado en CSV. La app se lanza con: `streamlit run 05_streamlit/app.py --server.port 8080`

7. Conclusion

Los datos obtenidos y analizados en este trabajo confirman y cuantifican la oportunidad de negocio de AI Financial Life Coach en el mercado espanol. Cuatro hallazgos son especialmente relevantes para el TFM:

- La morosidad en mínimos históricos (3,32% en 2024) indica un entorno financiero saneado que favorece la adopción de herramientas de gestión financiera personal.
- La tasa de ahorro en el 12,7% — por encima de la media histórica pre-pandemia — confirma que existe una base creciente de hogares con capacidad de ahorro que necesita orientación para optimizarlo.
- El descenso del Euríbor desde el 4,07% (2023) al 3,10% (2024) aumenta el interés de los ciudadanos por comparar alternativas de ahorro e inversión.
- El desempleo juvenil del 16,9% en el segmento 25-34 años sigue generando ingresos variables que dificultan la planificación financiera personal sin apoyo tecnológico.

Conclusión final: el contexto macroeconómico español de 2024 es el más favorable desde 2008 para el lanzamiento de una plataforma de gestión financiera personal. Los datos obtenidos a través de la API de Eurostat y el web scraping del Banco de España constituyen una base sólida, verificable y actualizada para alimentar el modelo analítico de AI Financial Life Coach y justificar su propuesta de valor ante el mercado español.

8. Referencias

- Eurostat Statistics API. (2024). API detailed guidelines. European Commission.
<https://ec.europa.eu/eurostat/web/user-guides/data-browser/api-data-access>
- Banco de España. (2024). Boletín Estadístico — Capítulo 4: Sistema Crediticio.
<https://www.bde.es/wbe/es/estadisticas/>
- Eurostat. (2024). Households — statistics on income, saving and investment. Statistics Explained.
- Banco de España. (2025). La morosidad bancaria cierra 2024 en el 3,32%. Boletín Estadístico.
- McKinney, W. (2022). Python for Data Analysis (3rd ed.). O'Reilly Media.