

OBTENCION DE DATOS PARA EL TFM

AI Financial Life Coach

Plataforma de Gestion Financiera Personal con IA

Asignatura	Obtencion de Datos para el TFM (Asignatura 5)
Master	Big Data y Business Intelligence
Institucion	Next Educacion
Mercado objetivo	Espana — Segmento 25-40 anos
Fuentes	Eurostat API + Banco de Espana (Web Scraping)
Equipo	C. Cuaya - C. Solis - J. Caceres - M. Merola - M. Lozano

1. Introduccion

El presente trabajo corresponde a la Asignatura 5 del Master en Big Data y Business Intelligence de Next Educacion y tiene como objetivo obtener, preparar y documentar los datos que sirvan de base para el Trabajo Fin de Master (TFM) del grupo: AI Financial Life Coach, una plataforma digital de gestion financiera personal basada en analitica de datos y modelos de aprendizaje automatico, dirigida al mercado espanol.

El mercado objetivo son jovenes profesionales de 25 a 40 anos residentes en Espana, con ingresos regulares o variables, alta adopcion digital y necesidad de ordenar sus finanzas sin conocimientos especializados. Para comprender este mercado y justificar la oportunidad de negocio, el grupo ha identificado cinco indicadores macroeconomicos clave: la tasa de ahorro de los hogares, la tasa de desempleo del segmento 25-34 anos, el Indice de Precios al Consumo, el Euribor a 12 meses y la tasa de morosidad bancaria. Estos indicadores caracterizan directamente la situacion financiera del segmento objetivo y validan las hipotesis del modelo de negocio.

Desde el punto de vista etico y legal, todas las fuentes utilizadas son institucionales y de acceso publico, los datos no contienen informacion personal identificable y el proceso de extraccion respeta en todo momento las condiciones de uso de los sitios consultados. No se han utilizado datasets descargados sin proceso propio: todos los datos han sido obtenidos directamente mediante las tecnicas de extraccion descritas en este documento.

2. Descripcion de las Fuentes y Justificacion de su Eleccion

Los datos han sido recopilados mediante las dos vias obligatorias establecidas por el enunciado del trabajo: consumo de una interfaz de programacion de aplicaciones (API) y web scraping. La eleccion de ambas fuentes responde a criterios de veracidad institucional, acceso publico, actualizacion periodica y coherencia directa con la tematica del TFM.

2.1 API publica — Eurostat (Oficina Estadistica de la Union Europea)

Eurostat es la oficina estadística oficial de la Unión Europea y constituye la fuente de referencia para los indicadores macroeconómicos de los Estados miembros. Publica sus datos a través de una interfaz de acceso programático pública, gratuita y sin necesidad de autenticación, lo que permite obtener series históricas actualizadas de forma automatizada y reproducible. Se han consultado tres conjuntos de datos:

Conjunto de datos	Indicador obtenido	Justificación para el TFM
Cuentas sectoriales trimestrales (hogares)	Tasa de ahorro bruto de los hogares españoles (%)	Cuantifica la capacidad de ahorro disponible en el mercado objetivo
Estadísticas de desempleo por edad	Tasa de desempleo 25-34 años en España (%)	Caracteriza la precariedad laboral e ingresos variables del segmento target
Índices de precios al consumo armonizados	Variación anual del IPC en España (%)	Refleja el poder adquisitivo real y la presión inflacionaria sobre el ahorro

La elección de Eurostat como fuente principal de la vía API se justifica por tres razones: primero, sus datos son de carácter oficial y auditados por la Comisión Europea, garantizando la máxima fiabilidad; segundo, cubre el periodo 2008-2024 con frecuencia trimestral o anual, permitiendo un análisis de largo plazo; tercero, es una fuente de uso habitual en estudios financieros y académicos, lo que facilita la comparabilidad de los resultados del TFM.

2.2 Web Scraping — Banco de España y Wikipedia

El Banco de España es la autoridad supervisora del sistema financiero español y publica mensualmente los datos de crédito dudoso y morosidad bancaria en su Boletín Estadístico, de acceso público en su sitio web oficial. Adicionalmente, se ha recurrido a la página de Wikipedia dedicada al Euríbor para obtener la serie histórica del tipo de interés de referencia europeo, cuya tabla estructurada es accesible para su extracción automatizada.

La elección del Banco de España como fuente de scraping se justifica porque es la única fuente oficial que publica los datos de morosidad del sistema crediticio español con periodicidad mensual. Esta

variable es clave para el TFM porque refleja el nivel de riesgo financiero del mercado objetivo y es uno de los indicadores que AI Financial Life Coach utilizara para contextualizar las recomendaciones de ahorro a sus usuarios.

Fuente	Indicador obtenido	Periodo cubierto	Periodicidad
Banco de Espana — Boletin Estadistico Cap.4	Tasa de morosidad bancaria (%)	2008-2024	Mensual
Wikipedia — Euribor historico	Euribor 12 meses media anual (%)	2008-2024	Anual

3. Proceso de Extraccion de Datos

La extraccion de datos se ha realizado en dos fases paralelas, una por cada via obligatoria, siguiendo en ambos casos un proceso sistematico y reproducible documentado en el repositorio tecnico del proyecto. A continuacion se describe el proceso a nivel conceptual y metodologico, sin incluir fragmentos de codigo.

3.1 Extraccion mediante API (Eurostat)

El proceso de extraccion via API consta de cuatro etapas. En primer lugar, se identifica el codigo de cada conjunto de datos en el catalogo publico de Eurostat y se construye la direccion de consulta incluyendo los filtros necesarios: pais de referencia (Espana), formato de respuesta (JSON) e indicador especifico dentro del conjunto de datos.

En segundo lugar, se realiza la solicitud al servidor de Eurostat mediante una peticion HTTP estandar. La respuesta se recibe en formato JSON-stat, un formato ligero especialmente disenado para la diseminacion de datos estadisticos que organiza la informacion en una estructura de dimensiones y valores.

En tercer lugar, se procesa la respuesta extrayendo las etiquetas temporales (trimestres o años) y los valores numéricos correspondientes, que se organizan en una tabla estructurada con columnas claramente definidas (periodo, valor, país, fuente e indicador).

En cuarto y último lugar, cada tabla se almacena en formato CSV en el directorio de datos sin procesar del repositorio, manteniendo la trazabilidad completa desde la fuente original hasta el dataset final. El proceso incluye un mecanismo de contingencia: si la API no está disponible en el entorno de ejecución, el sistema utiliza los datos históricos verificados directamente desde los informes publicados por Eurostat, garantizando la reproducibilidad del pipeline en cualquier entorno.

3.2 Extracción mediante Web Scraping (Banco de España)

El proceso de extracción mediante web scraping parte de la identificación de las páginas del Banco de España y de Wikipedia que contienen las tablas de datos de interés. Ambas fuentes presentan sus datos en formato de tabla HTML estructurada, lo que facilita su extracción automatizada.

La extracción se realiza en tres pasos. Primero, se descarga el contenido HTML de la página consultada, incluyendo en la solicitud una identificación de navegador estándar para respetar las políticas de acceso del servidor. Segundo, se analiza el contenido descargado para localizar las tablas de datos relevantes y extraer sus filas y columnas. Tercero, los datos extraídos se estructuran y se almacenan en formato CSV, con las mismas convenciones de nomenclatura que los datasets obtenidos vía API, para facilitar su posterior integración en el dataset consolidado.

Los datos de morosidad mensual del Banco de España (tasa de créditos dudosos sobre el total de crédito concedido) se han construido a partir de la serie histórica publicada en el Capítulo 4 del Boletín Estadístico, que es la referencia oficial del sistema crediticio español. La serie cubre el periodo 2008-2024 con 29 observaciones mensuales seleccionadas de forma representativa.

4. Limpieza y Preparación del Dataset

Una vez obtenidos los cinco datasets fuente, se ha llevado a cabo un proceso de limpieza y preparación estructurado en cuatro etapas, documentando en cada paso las decisiones tomadas y sus

justificaciones.

4.1 Eliminacion de duplicados

Se ha verificado sistematicamente la ausencia de registros duplicados en cada uno de los cinco datasets fuente. La comprobacion ha confirmado que ningun dataset contiene observaciones repetidas, lo que era esperable dada la naturaleza de series temporales con clave unica por periodo y pais. Decision tomada: no se han eliminado registros por duplicacion.

4.2 Tratamiento de valores faltantes

Se ha realizado una auditoria de valores nulos en todas las columnas de todos los datasets. El resultado ha sido la ausencia total de valores faltantes en los datos fuente, lo que es coherente con el origen institucional de las series (Eurostat y Banco de Espana publican series completas sin huecos en el periodo seleccionado). Decision tomada: no ha sido necesario aplicar ninguna tecnica de imputacion. No obstante, el pipeline incluye un mecanismo de imputacion por interpolacion lineal que se activaria automaticamente si se detectasen valores faltantes en futuras actualizaciones del dataset.

4.3 Estandarizacion de formatos y variables

Los cinco datasets fuente presentaban formatos temporales heterogeneos que han sido unificados siguiendo un criterio comun. Los datos trimestrales de Eurostat se expresaban en formato "2024-Q1"; se ha extraido el ano y el trimestre como columnas separadas para facilitar la agregacion. Los campos numericos se han verificado y convertido al tipo de dato correcto, eliminando posibles cadenas de texto que pudieran haber resultado del proceso de extraccion. Los nombres de columna se han estandarizado en formato snake_case (minusculas y guiones bajos) con nombres descriptivos en castellano, garantizando la coherencia entre todos los datasets.

4.4 Construccion del dataset consolidado

Los cinco datasets fuente se han integrado en un unico dataset anual consolidado mediante la agregacion de los datos trimestrales a frecuencia anual (calculando la media de los cuatro trimestres) y la union por el campo "anio" utilizando un cruce externo que preserva todos los anos disponibles en

cualquiera de las fuentes. El dataset final contiene 17 observaciones anuales (2008-2024) y 8 variables: el año de referencia, las cinco variables financieras, el país y la fuente.

Variable	Descripcion	Unidad	Fuente
anio	Año de referencia	Año	Calculada
tasa_ahorro_pct	Tasa de ahorro bruto de los hogares	%	Eurostat
tasa_desempleo	Tasa de desempleo segmento 25-34 años	%	Eurostat
ipc_variacion_anual_pct	Variación anual del IPC	%	Eurostat
euribor_pct	Euribor 12 meses — media anual	%	BdE / Wikipedia
tasa_morosidad_pct	Tasa de morosidad bancaria	%	Banco de España

5. Analisis Exploratorio de Datos (EDA)

El analisis exploratorio tiene como objetivo identificar los patrones, tendencias y relaciones entre variables que resultan mas relevantes para el modelo de negocio de AI Financial Life Coach. Se presentan cinco visualizaciones principales, cada una acompanada de sus observaciones y conclusiones.

5.1 Euribor frente a morosidad bancaria (2008-2024)

La comparativa entre el Euribor a 12 meses y la tasa de morosidad bancaria en el periodo 2008-2024 muestra dos fases claramente diferenciadas. La primera fase (2008-2013) corresponde a la crisis financiera: la morosidad escalo desde el 3,4% hasta el maximo historico del 13,6% en 2013, mientras el Euribor descendia bruscamente desde el 5,4% hasta niveles proximos a cero. La segunda fase (2014-2024) muestra una recuperacion sostenida: la morosidad ha descendido de forma ininterrumpida hasta el 3,3% en diciembre de 2024, su nivel mas bajo desde 2008, mientras el Euribor experimento un ciclo de tipos negativos (2016-2021) seguido de una subida acelerada en 2022-2023 y un descenso en 2024. El contexto de 2024 — morosidad en minimos y Euribor en descenso — es el mas favorable para el lanzamiento del producto desde el inicio del periodo analizado.




Figura 1. Euríbor 12 meses y tasa de morosidad bancaria en España (2008-2024). Fuentes: Banco de España y Eurostat.

5.2 Tasa de ahorro bruto de los hogares españoles (2015-2024)

La serie trimestral de la tasa de ahorro de los hogares españoles revela tres periodos significativos. Entre 2015 y 2019 el ahorro se mantuvo en una banda estrecha del 6,5% al 8,5%, con un patron estacional claro (el cuarto trimestre siempre registra valores superiores al resto del año). En 2020 se produjo un salto excepcional hasta el 17,6%, resultado directo del confinamiento y la caída forzada del consumo. Desde 2021 el ahorro ha convergido gradualmente hacia un nuevo equilibrio del 12-13%, estructuralmente superior a la media pre-pandemia. Este nivel más elevado implica que existe una base creciente de hogares españoles con capacidad real de ahorro que, sin embargo, carece de herramientas adecuadas para gestionarlo — exactamente el problema central que resuelve AI Financial Life Coach.




Figura 2. Tasa de ahorro bruto de los hogares españoles, datos trimestrales (2015-2024). Fuente: Eurostat, conjunto de datos nasq_10_ki.

5.3 Relacion entre desempleo juvenil y capacidad de ahorro

El diagrama de dispersion entre la tasa de desempleo del segmento 25-34 años y la tasa de ahorro anual de los hogares muestra una correlacion negativa en el periodo 2014-2019 (a menor desempleo, menor ahorro forzado y mayor consumo), con la notable excepcion de 2020. El punto de 2024 — desempleo en el 16,9% y ahorro en el 12,7% — representa la mejor combinacion de ambos indicadores desde 2008: el mercado objetivo esta mas empleado y ahorra mas. Sin embargo, el desempleo juvenil espanol sigue siendo el doble de la media europea, lo que genera una fraccion significativa de potenciales usuarios con ingresos variables o irregulares, perfil que AI Financial Life Coach esta especialmente disenada para atender.




Figura 3. Relación entre tasa de desempleo 25-34 años y tasa de ahorro hogares en España. Fuente: Eurostat.

5.4 Evolucion mensual de la morosidad (2015-2024)

La serie mensual de morosidad bancaria confirma una tendencia bajista consistente y practicamente ininterrumpida desde el 9,1% de enero de 2015 hasta el 3,3% de diciembre de 2024. La tasa de descenso ha sido especialmente pronunciada entre 2015 y 2019, con una ralentizacion en 2020 (la pandemia contuvo transitoriamente la caída) y una reanudacion del descenso desde 2021. El nivel de diciembre de 2024 es el mas bajo registrado desde noviembre de 2008. Para AI Financial Life Coach, este contexto implica que el sistema financiero español esta en su momento de mayor solidez en 16 años, lo que reduce la aversion al riesgo del consumidor y aumenta su predisposicion a adoptar nuevas herramientas de gestion financiera digital.




Figura 4. Evolucion mensual de la tasa de morosidad bancaria en Espana (2015-2024). Fuente: Banco de Espana, Boletin Estadistico, Capitulo 4.

5.5 Correlacion entre variables financieras

La matriz de correlacion entre las cinco variables financieras del dataset revela tres patrones relevantes. En primer lugar, se observa una correlacion positiva moderada entre el Euribor y la morosidad bancaria: los periodos de tipos de interes elevados tienden a coincidir con mayor dificultad de pago de los prestatarios. En segundo lugar, se detecta una correlacion negativa entre la tasa de desempleo y la tasa de ahorro, lo que indica que la mejora del empleo se traduce en mayor consumo y menor ahorro forzado, salvo en situaciones excepcionales como 2020. En tercer lugar, la tasa de ahorro muestra baja correlacion con el Euribor, lo que sugiere que el nivel de tipos de interes no es el principal determinante del ahorro familiar en Espana — factor importante para el diseno del modelo de recomendaciones de la plataforma.




Figura 5. Matriz de correlacion de Pearson entre las cinco variables financieras del dataset. Fuente: elaboracion propia a partir de Eurostat y Banco de Espana.

6. Herramienta de Exploracion: Streamlit

Como complemento al analisis estatico, el grupo ha desarrollado una aplicacion interactiva con Streamlit que permite explorar el dataset de forma dinamica sin necesidad de ejecutar codigo. La aplicacion muestra en tiempo real los cuatro indicadores principales del ultimo ano disponible con comparativa interanual, permite filtrar el periodo de analisis mediante un control deslizante y seleccionar las variables a visualizar mediante una lista de seleccion multiple. Las visualizaciones se actualizan instantaneamente en funcion de los filtros aplicados, facilitando la exploracion rapida de patrones y tendencias.

La aplicacion incluye ademas la posibilidad de descargar el dataset filtrado en formato CSV directamente desde la interfaz, lo que facilita su uso en fases posteriores del TFM. El codigo de la aplicacion se encuentra en el repositorio del proyecto y puede ejecutarse localmente siguiendo las instrucciones del README.

7. Conclusion

El trabajo ha demostrado la capacidad del grupo para localizar, extraer, limpiar y preparar datos relevantes para el TFM utilizando dos vías técnicas complementarias: el consumo de una API institucional y el web scraping de fuentes oficiales. El dataset final obtenido es sólido, verificable y actualizado hasta finales de 2024, y constituye una base adecuada para las fases siguientes del proyecto.

Los datos obtenidos son coherentes con la propuesta de valor de AI Financial Life Coach y aportan evidencia cuantitativa sobre cuatro aspectos clave del mercado objetivo español.

- La morosidad en mínimos históricos (3,3% en 2024) confirma un entorno financiero saneado que reduce la aversión al riesgo del consumidor y favorece la adopción de nuevas herramientas digitales de gestión financiera.
- La tasa de ahorro estabilizada en el 12,7% — muy por encima de la media pre-pandemia del 7,5% — confirma que existe una base creciente de hogares con capacidad de ahorro real que carece de orientación para optimizarlo, lo que valida directamente la necesidad del servicio.
- El descenso del Euríbor desde el máximo del 4,1% en 2023 hasta el 3,1% en 2024 aumenta el interés de los ciudadanos por comparar y optimizar sus productos de ahorro e inversión, ampliando la demanda potencial del servicio.
- El desempleo del 16,9% en el segmento 25-34 años, aunque en mínimos históricos, sigue generando una proporción significativa de usuarios con ingresos variables e irregulares — el perfil central del mercado objetivo de AI Financial Life Coach.

En conjunto, el análisis macroeconómico realizado confirma que el momento de lanzamiento de AI Financial Life Coach en el mercado español es el más favorable desde 2008. Los datos obtenidos no solo justifican la oportunidad de negocio sino que servirán como variables de contexto para el modelo analítico de la plataforma en las fases siguientes del TFM.

8. Referencias

- Eurostat. (2024). API Statistics — Guía detallada de acceso a datos. Comisión Europea. Recuperado de <https://ec.europa.eu/eurostat/web/user-guides/data-browser/api-data-access>
- Eurostat. (2024). Households — statistics on income, saving and investment. Statistics Explained. Comisión Europea.
- Banco de España. (2024). Boletín Estadístico — Capítulo 4: Sistema Crediticio. Recuperado de <https://www.bde.es/wbe/es/estadisticas/>
- Banco de España. (2025). Datos de créditos dudosos — diciembre 2024. Nota de prensa, enero 2025.
- McKinney, W. (2022). Python for Data Analysis (3rd ed.). O'Reilly Media.
- Waskom, M. (2021). Seaborn: Statistical Data Visualization. Journal of Open Source Software, 6(60), 3021.