

OBTENCION DE DATOS PARA EL TFM

AI Financial Life Coach

Plataforma de Gestion Financiera Personal con IA

Asignatura	Obtencion de Datos para el TFM (Asignatura 5)
Master	Big Data y Business Intelligence
Institucion	Next Educacion
Mercado objetivo	Espana — Segmento 25-40 anos
Fuentes	Eurostat API + Banco de Espana + Dataset sintetico INE 2025
Repositorio	https://github.com/mmerola99/TFM---Grupo_05
Equipo	C. Cuaya - C. Solis - J. Caceres - M. Merola - M. Lozano

1. Introduccion

El presente trabajo corresponde a la Asignatura 5 del Master en Big Data y Business Intelligence de Next Educacion. Su objetivo es obtener, preparar y documentar los datos que sirvan de base para el Trabajo Fin de Master (TFM): AI Financial Life Coach, una plataforma digital de gestion financiera personal basada en analitica de datos y modelos de aprendizaje automatico, dirigida a jovenes profesionales de 25 a 40 anos residentes en Espana.

El trabajo adopta un enfoque en dos niveles complementarios. El primer nivel consiste en la obtencion de indicadores macroeconomicos del mercado espanol mediante fuentes institucionales oficiales — API de Eurostat y web scraping del Banco de Espana — que contextualizan la oportunidad de negocio. El segundo nivel, que constituye el valor anadido del proyecto, consiste en la generacion de un dataset sintetico de 1.000 usuarios espanoles calibrado sobre datos reales del INE y Eurostat 2025, sobre el que se construyen tres modelos predictivos que demuestran las capacidades analiticas del producto.

Todos los datos han sido obtenidos o generados mediante proceso propio y verificable, respetando en todo momento los principios eticos y legales en la obtencion de datos: las fuentes institucionales son de acceso publico, no contienen informacion personal identificable, y el dataset sintetico no reproduce datos reales de usuarios.

2. Descripcion de las Fuentes y Justificacion

Se han utilizado tres tipos de fuentes, combinando las vias obligatorias de la asignatura con una fuente complementaria generada por el propio grupo.

2.1 API publica — Eurostat (contexto macroeconomico)

Eurostat publica sus datos a traves de una interfaz de acceso programatico publica, gratuita y sin autentificacion. Se han obtenido tres series historicas para Espana: la tasa de ahorro bruto de los hogares (2015-2025), la tasa de desempleo del segmento 25-34 anos (2010-2024) y la variacion anual del IPC (2019-2024). Estos indicadores contextualizan el entorno financiero del mercado objetivo y han

servido de base para calibrar los parametros del dataset sintetico.

2.2 Web Scraping — Banco de Espana

El Banco de Espana publica mensualmente la tasa de morosidad bancaria en su Boletin Estadistico. Junto con la serie historica del Euribor obtenida de Wikipedia, estos datos completan el contexto de riesgo crediticio del mercado espanol (2008-2024) y sirven como variables de referencia para las recomendaciones de la plataforma.

2.3 Dataset sintetico — Usuarios espanoles 2023-2026

El grupo ha generado un dataset sintetico de 1.000 usuarios espanoles con 41 meses de transacciones cada uno (enero 2023 - mayo 2026), produciendo 41.000 registros. Los parametros han sido calibrados directamente sobre estadisticas oficiales verificadas:

Parametro	Valor utilizado	Fuente oficial
Salario medio	2.385 euros/mes	INE — Encuesta Estructura Salarial 2025
Tasa de ahorro media	12%	Eurostat nasq_10_ki (2024-2025)
Gasto en vivienda	30% del salario	INE — Encuesta Presupuestos Familiares 2024
Inflacion mensual	0,19%-0,60%	INE — IPC mensual real 2023-2026
Euribor mayo 2026	2,2%	BCE / CaixaBank Research 2026
Crecimiento salarial	3% anual	INE — Salarios 2024-2025

El dataset incluye siete categorias de gasto (vivienda, alimentacion, transporte, ocio, salud, educacion y otros), cuatro perfiles laborales (junior, medio, senior, freelance) y tres clasificaciones de perfil de ahorro (buen ahorrador, ahorro moderado, ahorro insuficiente). La variable del IPC mensual real permite que los gastos evolucionen de forma realista a lo largo del periodo, reflejando el ciclo inflacionario espanol de 2023-2026.

3. Proceso de Extraccion y Generacion de Datos

3.1 Extraccion mediante API (Eurostat)

Para cada uno de los tres conjuntos de datos de Eurostat, el proceso siguió cuatro etapas. Primero, se identificó el código del dataset en el catálogo público y se construyó la dirección de consulta con los filtros de país (España) y formato de respuesta. Segundo, se realizó la solicitud al servidor y se recibió la respuesta en formato JSON-stat, un estándar ligero para la diseminación de datos estadísticos. Tercero, se extrajeron las etiquetas temporales y los valores numéricos de la respuesta. Cuarto, los datos se almacenaron en formato CSV en el directorio de datos sin procesar. El proceso incluye un mecanismo de contingencia que utiliza datos históricos verificados si la API no está disponible en el entorno de ejecución.

3.2 Extraccion mediante Web Scraping (Banco de España)

La extracción del Banco de España y Wikipedia siguió tres pasos. Primero, se descargó el contenido HTML incluyendo una identificación de navegador estándar para respetar las políticas de acceso. Segundo, se analizaron las tablas HTML para localizar los datos relevantes. Tercero, los datos se estructuraron y almacenaron en CSV con las mismas convenciones que los obtenidos vía API.

3.3 Generacion del dataset sintetico de usuarios

El dataset sintético se generó mediante un proceso de simulación controlada en cuatro fases. En la primera fase se definieron los parámetros de distribución para cada perfil de usuario basándose en las estadísticas oficiales descritas en la sección anterior. En la segunda fase se generó para cada uno de los 1.000 usuarios un salario base aleatorio según su perfil, una propensión al ahorro individual y unos porcentajes de gasto por categoría. En la tercera fase se simuló mes a mes la evolución de ingresos y gastos, aplicando el IPC mensual real y un crecimiento salarial anual del 3%. En la cuarta fase se calcularon el ahorro mensual, la tasa de ahorro y la clasificación del perfil de ahorro para cada registro.

4. Limpieza y Preparacion del Dataset

El proceso de limpieza se aplico tanto a los datasets obtenidos de fuentes externas como al dataset sintetico generado por el grupo.

4.1 Datasets de fuentes externas (Eurostat y BdE)

Se verifico la ausencia de duplicados y valores faltantes en los cinco datasets fuente, con resultado negativo en ambos casos. Los campos temporales se estandarizaron extrayendo el ano y trimestre de los periodos en formato "2024-Q1". Los valores numericos se convirtieron al tipo correcto y los nombres de columna se unificaron en formato snake_case. Finalmente, los cinco datasets se integraron en un dataset consolidado anual de 17 observaciones (2008-2024) mediante agregacion y union por el campo del ano de referencia.

4.2 Dataset sintetico de usuarios

El dataset sintetico fue disenado para no requerir limpieza posterior, al generarse con restricciones integradas que garantizan la calidad: salario minimo de 1.100 euros (por encima del SMI espanol 2025), ajuste automatico si el gasto total supera el ingreso disponible, y valores de IPC acotados a rangos historicamente observados en Espana. Se realizaron verificaciones de coherencia entre variables: la tasa de ahorro calculada coincide con la diferencia entre salario y gasto total, y la clasificacion del perfil de ahorro es consistente con los umbrales definidos.

Variable	Descripcion	Tipo	Rango observado
user_id	Identificador unico del usuario	Discreta	1 — 1.000
fecha	Mes de referencia	Temporal	2023-01 — 2026-05
edad	Edad del usuario	Discreta	25 — 40 anos
perfil	Tipo de empleo	Cualitativa	junior/medio/senior/freelance
salario	Ingreso mensual neto	Continua	1.100 — 6.500 euros

vivienda	Gasto en alquiler/hipoteca	Continua	300 — 2.000 euros
alimentacion	Gasto en alimentacion	Continua	100 — 800 euros
gasto_total	Suma de todos los gastos	Continua	900 — 5.500 euros
ahorro	Salario menos gasto total	Continua	-200 — 2.500 euros
tasa_ahorro_pct	Ahorro como % del salario	Continua	-10% — 45%
perfil_ahorro	Clasificacion del ahorrador	Cualitativa	3 categorias

5. Analisis Exploratorio de Datos (EDA)

El analisis exploratorio se estructura en dos bloques: el primero sobre el contexto macroeconomico espanol obtenido de fuentes institucionales, y el segundo sobre el comportamiento financiero de los usuarios simulados, que es el nucleo del proyecto TFM.

5.1 Contexto macroeconomico — Euribor y morosidad (2008-2024)

La comparativa entre el Euribor y la morosidad bancaria revela dos fases historicas. La crisis de 2008-2013 elevo la morosidad hasta el maximo del 13,6%, mientras el Euribor descendia desde el 5,4%. La recuperacion de 2014-2024 muestra un descenso sostenido de la morosidad hasta el 3,3% en 2024, su minimo desde 2008. El Euribor experimento tipos negativos entre 2016 y 2021, una subida acelerada en 2022-2023 y un descenso en 2024 hasta el 3,1%, con previsiones del BCE de estabilizacion en torno al 2,2% en 2026. Este contexto es el mas favorable para el lanzamiento del producto desde el inicio del periodo analizado.

[Figura 1. Euribor 12 meses y tasa de morosidad bancaria en Espana (2008-2024). Fuentes: Banco de Espana y Eurostat.]

5.2 Tasa de ahorro y desempleo juvenil (2015-2024)

La tasa de ahorro se estabilizo en torno al 12-13% en 2024, estructuralmente por encima de la media pre-pandemia del 7,5%, lo que confirma una base creciente de hogares con capacidad de ahorro. El desempleo del segmento 25-34 anos descendio al 16,9% en 2024, su minimo historico, aunque sigue siendo el doble de la media europea. Ambos indicadores validan directamente el mercado objetivo de AI Financial Life Coach: usuarios con capacidad de ahorro creciente pero con ingresos aun variables o irregulares que necesitan orientacion para optimizar sus finanzas.

[Figura 2. Tasa de ahorro bruto de los hogares espanoles (trimestral, 2015-2024). Fuente: Eurostat nasq_10_ki.]

5.3 Analisis del dataset sintetico de usuarios

El dataset de 41.000 registros confirma que los parametros de simulacion son coherentes con la realidad espanola. El salario medio resultante es de 2.387 euros mensuales, practicamente identico al

dato del INE (2.385 euros). La tasa de ahorro media es del 18,7%, ligeramente superior a la media nacional del 12% por efecto de la distribucion de perfiles (mayor proporcion de perfiles medio y senior). La distribucion de perfiles de ahorro muestra que el 65% de los registros corresponde a buenos ahorradores, el 32% a ahorro moderado y el 3% a ahorro insuficiente — proporciones coherentes con el mercado objetivo seleccionado (empleados con ingresos medios-altos).

5.4 Resultados de los modelos predictivos

Sobre el dataset sintetico se han construido tres modelos que constituyen el nucleo analitico de AI Financial Life Coach.

- Modelo 1 — Regresion Lineal para la prediccion del ahorro mensual: el modelo explica el 100% de la varianza del ahorro ($R^2 = 1,0000$) con un error medio absoluto de 0 euros, lo que era esperable dado que el ahorro es una funcion determinista del salario y los gastos en el dataset sintetico. En datos reales, donde intervienen factores no observados, el R^2 sera menor pero el modelo mantendra su capacidad de identificar los principales determinantes del ahorro individual.
- Modelo 2 — Regresion Logistica para la clasificacion del perfil de ahorro: el modelo alcanza una precision global del 96,3%, con un Recall perfecto en la clase "ahorro_insuficiente" (1,00), que es la mas critica para las alertas proactivas de la plataforma. La clase "buen_ahorrador" obtiene una precision del 100%, lo que indica que el modelo no genera falsos positivos en el segmento de mayor valor.
- Modelo 3 — Proyeccion de serie temporal: el modelo proyecta un ahorro medio de 370 euros en junio de 2026 con una tendencia descendente gradual hasta 354 euros en noviembre de 2026, coherente con las previsiones de CaixaBank Research que anticipan un descenso moderado de la tasa de ahorro espanola en el segundo semestre de 2026 ante el aumento del consumo.




Figura 3. Proyección del ahorro medio mensual para junio-noviembre 2026 (Modelo 3). La línea discontinua roja muestra los valores proyectados sobre la tendencia histórica.




Figura 4. Matriz de confusión del Modelo 2 (Regresión Logística). Accuracy global: 96,3%. Recall clase ahorro insuficiente: 100%.

6. Herramienta de Exploracion y Simulacion: Streamlit

La aplicacion Streamlit desarrollada trasciende la funcion de simple dashboard descriptivo para convertirse en un simulador predictivo interactivo, que constituye el prototipo funcional de la interfaz de usuario de AI Financial Life Coach. La aplicacion se organiza en cuatro pestanas.

- Simulador Personal: el usuario introduce su perfil (edad, salario, gastos por categoria) y el sistema devuelve en tiempo real el ahorro mensual predicho por el Modelo 1, la clasificacion del perfil de ahorro del Modelo 2 y una recomendacion personalizada adaptada a cada caso. Es el nucleo funcional del producto y demuestra de forma concreta la propuesta de valor de la plataforma.
- Analisis del Dataset: exploracion interactiva del dataset sintetico con filtros por perfil laboral, rango de edad y periodo temporal. Incluye visualizaciones dinamicas de la distribucion del ahorro, el perfil por tipo de empleo y la evolucion mensual.
- Rendimiento de Modelos: metricas detalladas de los dos modelos de clasificacion y regresion, con graficos de ahorro real vs. predicho, importancia de variables y matriz de confusion.
- Proyeccion Temporal: visualizacion de la proyeccion del Modelo 3 con los valores mensuales proyectados para junio-noviembre 2026 e interpretacion del contexto macroeconomico que la fundamenta.

7. Conclusion

El trabajo ha cumplido y superado los requisitos minimos de la asignatura. Se han utilizado las dos vias obligatorias de obtencion de datos — API y web scraping sobre fuentes institucionales oficiales — y se ha anadido una fuente complementaria generada por el propio grupo: un dataset sintetico de 1.000 usuarios calibrado sobre estadisticas reales del INE y Eurostat 2025, que constituye la base de datos principal para el desarrollo del TFM.

Los tres modelos predictivos construidos sobre este dataset demuestran que el grupo es capaz de ir mas alla de la obtencion y descripcion de datos para construir herramientas analiticas con valor real para el negocio. Los resultados son coherentes con el proyecto TFM y proporcionan una base tecnica

solida para las fases siguientes.

- El contexto macroeconomico espanol de 2024-2026 — morosidad en minimos, ahorro por encima de la media historica y Euribor en descenso — es el mas favorable desde 2008 para el lanzamiento de una plataforma de gestion financiera personal.
- El dataset sintetico de 41.000 registros, calibrado sobre datos reales verificados, constituye una base de entrenamiento adecuada para el modelo de recomendaciones de AI Financial Life Coach en su fase MVP.
- El Modelo 2 de clasificacion alcanza un 96,3% de precision con Recall perfecto en la clase critica, lo que lo hace directamente utilizable como motor de clasificacion de perfiles en la plataforma.
- La Streamlit desarrollada funciona como prototipo funcional de la interfaz de usuario, demostrando la viabilidad tecnica del producto de forma concreta.

En conjunto, este trabajo demuestra que el grupo dispone de las competencias tecnicas necesarias para obtener, preparar y modelar datos financieros con valor real para el desarrollo de AI Financial Life Coach. Los datos, modelos y herramientas producidos en esta asignatura constituyen el punto de partida solido y justificado para el TFM.

8. Referencias

- Eurostat. (2025). API Statistics — Guia de acceso a datos. Comision Europea.
<https://ec.europa.eu/eurostat/web/user-guides/data-browser/api-data-access>
- INE. (2025). Encuesta de Estructura Salarial 2025. Instituto Nacional de Estadistica.
<https://www.ine.es>
- INE. (2025). Encuesta de Presupuestos Familiares 2024. Instituto Nacional de Estadistica.
- Banco de Espana. (2025). Boletin Estadistico — Capitulo 4: Sistema Crediticio.
<https://www.bde.es/wbe/es/estadisticas/>
- CaixaBank Research. (2026). Household savings, income and finances in Spain: how did they fare in 2025 and what can we expect for 2026? <https://www.caixabankresearch.com>

- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- McKinney, W. (2022). Python for Data Analysis (3rd ed.). O'Reilly Media.